

UNIVERSIDAD TÉCNICA PARTICULAR DE LOJA

ESTADO DEL ARTE CON ÉNFASIS EN INGENIERÍA DE DATOS

Autor: Daniel Matute

Carrera: Computación

Practicum 1.2

I. RESUMEN / ABSTRACT

En este documento se presenta la investigación sobre el estado del arte enfocado en la Ingeniería de Datos, disciplina fundamental que habilita las áreas de analítica y visualización. Se explora la construcción de pipelines modernos para mover información a gran escala, centrando la atención en la evolución de los procesos ETL hacia el modelo predominante ELT, el cual prioriza la carga de datos crudos en el warehouse para su posterior transformación. Asimismo, se analizan tecnologías clave en el panorama actual: la extracción mediante APIs, el procesamiento distribuido con Apache Spark para grandes volúmenes de información, y la transformación analítica utilizando herramientas basadas en SQL. Finalmente, se revisa el papel estratégico de orquestadores para la automatización de flujos en Python, destacando la importancia de implementar la calidad de datos y la observabilidad como una capa transversal y proactiva, sentando así las bases necesarias para resolver los retos operativos de la universidad.

II. INTRODUCCIÓN

El presente trabajo, enmarcado en el Prácticum 1.2 de la carrera de Computación de la UTPL, se alinea con los retos operativos manejados por la Dirección General de Tecnologías para la Información y Transformación Digital (DGTITD). Esta dirección constituye el motor tecnológico que sostiene el funcionamiento integral de los sistemas universitarios. Dentro de este ecosistema, la línea de Ingeniería de Datos asume un rol crítico: actuar como el habilitador fundamental que estructura y limpia los datos para que las áreas de analítica y visualización puedan operar con efectividad.

El flujo de trabajo moderno demanda el diseño de pipelines capaces de mover información a escala

de manera limpia y lista para su consumo. La relevancia de este estudio radica en el alto volumen de datos generados diariamente por la UTPL a través de APIs y sistemas académicos. La falta de procesos claros de extracción, carga y transformación (ETL/ELT) imposibilita la toma de decisiones informadas. En este sentido, la investigación del estado del arte persigue identificar las metodologías y herramientas que el mercado emplea para gestionar grandes volúmenes de datos sin comprometer la estabilidad del sistema.

El propósito central de este documento es definir el stack técnico más adaptable a las necesidades de la universidad actual, establecer metodologías para garantizar la calidad de los datos desde la fuente, y evaluar el impacto de la orquestación de flujos automatizados. Este análisis proporciona los fundamentos teóricos necesarios para la construcción de soluciones técnicas a los retos del backlog de la DGTITD.

III. MARCO CONCEPTUAL

La Ingeniería de Datos requiere la comprensión de herramientas y procesos específicos que sustentan el manejo de la información en el entorno universitario.

- **Pipelines de datos:** Estructura arquitectónica que permite el tránsito automatizado de la información a través de diversas fases del ciclo de vida de los datos: ingesta, almacenamiento, transformación y servicio [1].
- **ETL y ELT:** Modelos de procesamiento de datos. El paradigma clásico ETL (Extraer, Transformar y Cargar) ha evolucionado hacia el estándar ELT (Extraer, Cargar y Transformar). Este último carga los datos crudos directamente en el almacén de datos

(data warehouse) y realiza las transformaciones internamente, aprovechando el alto rendimiento de cómputo de los motores de bases de datos modernos [2].

- **APIs (Application Programming Interface):** Estilos arquitectónicos y contratos informáticos que permiten la comunicación estandarizada entre diferentes sistemas de software. Son el mecanismo esencial para la extracción de información desde sistemas transaccionales, siendo REST el formato predominante [3].
- **Apache Spark y Procesamiento Distribuido:** Framework unificado utilizado cuando las librerías tradicionales resultan insuficientes ante conjuntos de datos masivos. Spark realiza procesamiento paralelo y en memoria, dividiendo la carga de trabajo entre múltiples nodos en un clúster [4].
- **Orquestación de flujos:** Uso de herramientas basadas en grafos acíclicos dirigidos (DAGs), como Prefect o Airflow, que convierten funciones (ej. Python) en flujos de trabajo programables, permitiendo la automatización, el monitoreo continuo y la gestión de dependencias y reintentos [1].
- **Transformación modular:** Implementación de herramientas como dbt (Data Build Tool) para el modelado analítico, las cuales aplican principios de ingeniería de software al código SQL, añadiendo capacidades de versionamiento, testing automatizado y documentación de linaje [1].

TRABAJOS RELACIONADOS

A nivel global, la Ingeniería de Datos se ha consolidado como el núcleo operativo de diversas instituciones y empresas tecnológicas. En el sector corporativo, organizaciones a gran escala están migrando hacia arquitecturas descentralizadas como Data Mesh. Bajo este paradigma sociotécnico, en lugar de centralizar el manejo de datos en un solo equipo monolítico, los departamentos individuales operan como dominios dueños de sus propios datos, sirviéndolos como un "producto de datos" consumible [5].

Asimismo, en el ámbito industrial se observa una adopción masiva de Apache Spark en empresas con altos volúmenes transaccionales, apoyándose en su tolerancia a fallos y procesamiento en memoria para acelerar la generación de analítica [4]. En paralelo, la literatura actual enfatiza el paso de sistemas ETL rígidos hacia plataformas integrales de observabilidad, democratizando las transformaciones a través del lenguaje SQL estructurado y garantizando alertas tempranas ante anomalías [1].

HERRAMIENTAS Y TECNOLOGÍAS

El stack técnico predominante en Ingeniería de Datos se estructura en varias capas. En la base del procesamiento, lenguajes como Python han establecido el estándar para la manipulación de estructuras de datos mediante librerías fundamentales como pandas [6].

Para datasets masivos que exceden la capacidad de memoria de un solo servidor, la herramienta estándar de la industria es Apache Spark, que a través de su interfaz PySpark permite escalar el procesamiento de manera distribuida [4]. En la capa de transformación dentro del almacén de datos, el enfoque del Modern Data Stack utiliza marcos de trabajo (como dbt) que inyectan pruebas de calidad (testing) y control de versiones directamente en los flujos SQL, garantizando transformaciones correctas y documentando el linaje de los datos de principio a fin [1]. Todo este ecosistema se unifica mediante herramientas de orquestación que gobiernan la ejecución coordinada de estas tecnologías.

IV. TENDENCIAS Y FUTURO

En un horizonte a corto y mediano plazo, la principal tendencia arquitectónica es la consolidación del modelo Data Lakehouse. Esta arquitectura de plataforma abierta fusiona la economía y flexibilidad de almacenamiento de un Data Lake con el rendimiento de consultas y la gestión transaccional (ACID) de un Data Warehouse tradicional [7]. Para el entorno universitario, esto representa la ventaja de unificar flujos de machine learning y dashboards analíticos

sobre una sola capa de datos sin necesidad de duplicarlos.

Otra macro tendencia es la Observabilidad de Datos integral. Evolucionando desde las pruebas estáticas, los sistemas modernos emplean recolección de metadatos para comprender el comportamiento de los pipelines y emitir alertas proactivas ante caídas de volumen o cambios de esquema inesperados, garantizando la confiabilidad de la información [1].

Finalmente, se proyecta una integración madura entre la ingeniería de datos y el MLOps (Machine Learning Operations). Las investigaciones recientes destacan que el mayor desafío para la inteligencia artificial en producción no son los algoritmos, sino la gestión, limpieza y validación continua de los datos que los alimentan [8]. Las tuberías de datos modernas buscan sostener este proceso como un ciclo unificado.

V. CONCLUSIONES

Del análisis del estado del arte, se desprenden las siguientes conclusiones fundamentales para abordar los retos técnicos:

1. La adopción del modelo ELT frente al clásico ETL representa una necesidad técnica ineludible. Extraer y cargar primero la información cruda incrementa la agilidad de los pipelines y maximiza la capacidad de cómputo de las bases de datos modernas durante la fase de transformación [2].
2. La orquestación automatizada es un requisito indispensable para escalar las operaciones, permitiendo gestionar dependencias complejas y mitigar fallos mediante reintentos autónomos.
3. La calidad de los datos exige un enfoque transversal proactivo. La implementación temprana de observabilidad y validación estructural es la única garantía de que los modelos analíticos consuman información íntegra desde su origen.

VI. REFERENCIAS

- [1] J. Reis and M. Housley, *Fundamentals of Data Engineering: Plan and Build Robust Data Systems*. O'Reilly Media, 2022.
- [2] M. Muniswamaiah, T. Agerwala, and C. C. Tappert, "Big data analytics and transformation using ELT," in *2020 IEEE International Conference on Big Data*, 2020, pp. 5752-5754.
- [3] R. T. Fielding, "Architectural styles and the design of network-based software architectures," Ph.D. dissertation, University of California, Irvine, 2000.
- [4] M. Zaharia et al., "Apache Spark: A unified engine for big data processing," *Communications of the ACM*, vol. 59, no. 11, pp. 56-65, 2016.
- [5] Z. Dehghani, *Data Mesh: Delivering Data-Driven Value at Scale*. O'Reilly Media, 2022.
- [6] W. McKinney, "Data structures for statistical computing in python," in *Proceedings of the 9th Python in Science Conference*, 2010, pp. 51-56.
- [7] M. Armbrust, A. Ghodsi, R. Xin, and M. Zaharia, "Lakehouse: A new generation of open platforms that unify data warehousing and advanced analytics," in *CIDR 2021*, 2021.
- [8] N. Polyzotis, S. Roy, S. E. Whang, and M. Zinkevich, "Data management challenges in production machine learning," in *Proceedings of the 2018 International Conference on Management of Data*, 2018, pp. 1723-1726.