

ESTADO DEL ARTE CON ÉNFASIS EN INGENIERÍA DE DATOS

Universidad Técnica
Particular de Loja



Autor: **DANIEL MATUTE**
Carrera: **COMPUTACIÓN**
PRACTICUM 1.2

1. Resumen / Abstract

En este documento se presenta la investigación sobre el estado del arte enfocado en la Ingeniería de Datos, disciplina fundamental que habilita las áreas de analítica y visualización. Se explora la construcción de pipelines modernos para mover información a gran escala, centrando la atención en la evolución de los procesos ETL hacia el modelo predominante ELT, el cual prioriza la carga de datos crudos en el *warehouse* para su posterior transformación. Asimismo, se analizan tecnologías clave en el panorama actual: la extracción mediante APIs, el procesamiento distribuido con Apache Spark para grandes volúmenes de información, y la transformación analítica utilizando dbt. Finalmente, se revisa el papel estratégico de orquestadores como Prefect para la automatización de flujos en Python, destacando la importancia de implementar la calidad de datos y la observabilidad como una capa transversal y proactiva, sentando así las bases necesarias para resolver los retos operativos de la universidad.

2. Introducción

El presente trabajo, enmarcado en el Prácticum 1.2 de la carrera de Computación de la UTPL, se alinea con los retos operativos manejados por la Dirección General de Tecnologías para la Información y Transformación Digital (DGTITD). Esta dirección constituye el motor tecnológico que sostiene el funcionamiento integral de los sistemas universitarios. Dentro de este ecosistema, la línea de Ingeniería de Datos asume un rol crítico: actuar como el habilitador fundamental que estructura y limpia los datos para que las áreas de analítica y visualización puedan operar con efectividad.

El flujo de trabajo moderno demanda el diseño de pipelines capaces de mover información a escala de manera limpia y lista para su consumo. La relevancia de este estudio radica en el alto volumen de datos generados diariamente por la UTPL a través de APIs y sistemas académicos. La falta de procesos claros de extracción, carga y transformación (ETL/ELT) imposibilita la toma de decisiones informadas. En este sentido, la investigación del estado del arte persigue identificar las herramientas idóneas (como

Apache Spark o dbt) que el mercado emplea para gestionar grandes volúmenes de datos sin comprometer la estabilidad del sistema.

El propósito central de este documento es definir el stack técnico más adaptable a las necesidades de la universidad actual, establecer metodologías para garantizar la calidad de los datos desde la fuente, y evaluar el impacto de la orquestación de flujos automatizados con Prefect. Este análisis proporciona los fundamentos teóricos necesarios para la construcción de soluciones técnicas a los retos del *backlog* de la DGTITD.

3. Marco Conceptual

La Ingeniería de Datos requiere la comprensión de herramientas y procesos específicos que sustentan el manejo de la información en el entorno universitario.

Pipelines de datos: Estructura o "tubería" que permite el tránsito de la información a través de diversas capas: ingesta, almacenamiento, transformación y consumo final para visualización (DGTITD, 2026).

ETL y ELT: Modelos de procesamiento de datos. ETL (Extraer, Transformar y Cargar) ha evolucionado hacia el estándar ELT (Extraer, Cargar y Transformar). Este último modelo carga los datos crudos directamente en el data warehouse y realiza las transformaciones internamente, aprovechando la velocidad superior de las bases de datos modernas (DGTITD, 2026).

APIs (Application Programming Interface): Contratos informáticos que permiten la comunicación entre diferentes sistemas. Son esenciales para la extracción de información desde sistemas internos o servicios externos, siendo REST el formato más (DGTITD, 2026).

Apache Spark y Procesamiento Distribuido: Framework utilizado cuando librerías tradicionales (como pandas) resultan insuficientes ante conjuntos de datos masivos. Spark realiza procesamiento distribuido, dividiendo la carga de trabajo entre múltiples máquinas (DGTITD, 2026).

Orquestación con Prefect: Herramienta moderna que convierte funciones de Python en flujos de trabajo programables, permitiendo la automatización de horarios, el

monitoreo continuo y la ejecución de reintentos automáticos en caso de fallos (DGTITD, 2026).

Transformación con dbt: Herramienta estandarizada (Data Build Tool) para el modelado analítico. Transforma datos utilizando código SQL, añadiendo capacidades de versionamiento, testing y documentación (DGTITD, 2026).

4. Trabajos Relacionados

A nivel global, la Ingeniería de Datos se ha consolidado como el núcleo operativo de diversas instituciones y empresas tecnológicas. En el sector educativo, grandes universidades están migrando hacia arquitecturas de Data Mesh. Bajo este paradigma, en lugar de centralizar el manejo de datos en un solo equipo, departamentos individuales (como finanzas o registro académico) operan como dueños de sus propios datos, entregándolos como un "producto" consumible por otras áreas.

En el sector corporativo, se observa una transición desde los sistemas ETL tradicionales hacia plataformas avanzadas de Observabilidad de Datos, las cuales notifican en tiempo real cualquier ruptura de pipeline o anomalía en los datos entrantes (Orchestra, s.f.). Por otra parte, empresas con un alto volumen transaccional emplean extensivamente Apache Spark apoyándose en clústeres de servidores para acelerar la generación de reportes (Databricks, s.f.). Simultáneamente, la adopción de dbt se ha vuelto imperativa, democratizando la ingeniería de datos al permitir que analistas estructuren transformaciones complejas empleando únicamente bases sólidas de SQL (dbt Labs, s.f.).

5. Herramientas y Tecnologías

El stack técnico predominante en Ingeniería de Datos se estructura en varias capas. En la base, Python es el lenguaje más versátil, apoyado por librerías como pandas (DGTITD, 2026). Paralelamente, el dominio de SQL avanzado sigue siendo imprescindible para consultas eficientes (DGTITD, 2026).

Para datasets masivos (como millones de registros académicos), la herramienta clave es Apache Spark, cuyo motor distribuido se integra con Python a través de PySpark, evitando fallos de memoria (Databricks, s.f.). En la capa de transformación dentro del

almacén de datos, dbt (Data Build Tool) aplica principios de ingeniería de software (control de versiones, integración continua, testing) al SQL, garantizando transformaciones correctas y documentando el linaje de los datos (dbt Labs, s.f.).

La automatización integral de los pipelines se logra con un orquestador moderno que se integra fácilmente con Python, permitiendo programar flujos, gestionar reintentos y tener visibilidad en tiempo real (DGTITD, 2026). Finalmente, herramientas de visualización como Power BI (Microsoft, s.f.) y Looker Studio consumen los datos refinados para presentar indicadores estratégicos a los directivos.

6. Tendencias y Futuro

En un horizonte de corto y mediano plazo (1 a 3 años), la principal tendencia arquitectónica en la ingeniería de datos es el Data Lakehouse. Esta tecnología fusiona la capacidad de almacenamiento económico y flexible de un Data Lake (ideal para logs y archivos no estructurados) con la organización, seguridad y velocidad transaccional de un Data Warehouse tradicional (MinIO, s.f.; ClickHouse, s.f.). Para el entorno universitario, esto representa la ventaja operativa de unificar flujos de analítica y dashboards de Power BI en un ecosistema centralizado, mitigando la necesidad de duplicar y trasladar datos entre silos (DGTITD, 2026).

Otra macrotendencia es la consolidación de la Observabilidad de Datos. Evolucionando desde las pruebas de integridad básicas, las plataformas modernas emplean modelos de aprendizaje para comprender el comportamiento estándar de los pipelines. Ante anomalías, como caídas en el volumen de registros o latencias inusuales, el sistema emite alertas proactivas antes de que el fallo se propague a los tableros de control ejecutivos (Orchestra, s.f.).

Finalmente, se proyecta una integración profunda entre los flujos de ingeniería y el MLOps (Machine Learning Operations) básico. En contraposición a la separación histórica entre los equipos de IA e ingeniería de datos, el paradigma actual requiere que los modelos de inteligencia artificial se alimenten de datos estructurados desde su origen. Las herramientas modernas de orquestación consolidan este proceso en un ciclo único y estable, donde la ingeniería proporciona una base resiliente para el despliegue de soluciones de IA.

7. Conclusiones

Del análisis del estado del arte, se desprenden las siguientes conclusiones fundamentales para abordar los retos técnicos:

- La adopción del modelo ELT frente al clásico ETL representa una necesidad técnica ineludible. Extraer y cargar primero la información cruda incrementa la agilidad de los pipelines y maximiza la capacidad de cómputo de las bases de datos modernas durante la fase de transformación.

- La orquestación automatizada es un requisito indispensable para escalar las operaciones. La implementación de herramientas como Prefect erradica el trabajo manual, gestiona los reintentos de forma autónoma y proporciona trazabilidad integral de la infraestructura de datos.
- La calidad de los datos exige un enfoque transversal proactivo. La implementación temprana de metodologías de observabilidad es la única garantía de que herramientas analíticas potentes y visualizaciones gerenciales consuman información fidedigna e íntegra desde su origen.

8. Referencias

ClickHouse. (s.f.). *Resource hub*. <https://clickhouse.com/resources/>

Databricks. (s.f.). *What is PySpark?*. <https://www.databricks.com/glossary/pyspark>

dbt Labs. (s.f.). *What is dbt?*. <https://www.getdbt.com/product/what-is-dbt/>

DGTITD. (2026). *Prácticum Abril Agosto 2026 - Sesión Teórica: Bases Conceptuales* [Diapositivas]. Universidad Técnica Particular de Loja.

Microsoft. (s.f.). *What is Power BI?*. <https://learn.microsoft.com/en-us/power-bi/fundamentals/power-bi-overview>

MinIO. (s.f.). *What is a Data Lakehouse?*. <https://www.min.io/learn/data-lakehouse>

Orchestra. (s.f.). *Data Observability with Monte Carlo*. <https://www.getorchestra.io/guides/data-observability-with-monte-carlo-enhancing-data-integrity>