

Pipeline de Datos: Del CSV Crudo al Dashboard

Universidad Técnica Particular de Loja (UTPL) Carrera: Computación (4to Ciclo)

Asignatura: Prácticum 1.2 - Estado del Arte con énfasis en Ingeniería de Datos

Autor: Daniel Matute

Descripción del Proyecto

Este proyecto implementa un pipeline de datos completo (ETL) utilizando el Archivo Maestro de Instituciones Educativas (AMIE) del Ministerio de Educación del Ecuador (MINEDUC). El objetivo es procesar un dataset gubernamental real, superando problemas comunes de calidad de datos, para finalmente construir un dashboard interactivo que responda a preguntas analíticas específicas sobre el panorama educativo del país.

Stack Tecnológico

- **Lenguaje:** Python 3.10+
- **Librerías:** pandas (limpieza y manipulación), sqlalchemy (conexión a base de datos).
- **Base de Datos:** SQLite (local).
- **Visualización:** Power BI Desktop (conexión vía script de Python).

Estructura de Fases y Ejecución

Fase 1: Exploración y Diagnóstico (exploracion.py)

Se realizó una inspección inicial del archivo CSV (codificado en latin-1 con separador ;) para entender la estructura original sin realizar modificaciones.

- **Dimensiones:** El dataset crudo contiene 16,201 filas (instituciones) y 74 columnas.
- **Hallazgos:** Se identificaron columnas clave con tildes y espacios (ej. Nivel Educación, Nombre_Institución), lo cual dificulta la manipulación programática. Se observó una predominancia de instituciones de sostenimiento Fiscal (12,419) seguidas por las Particulares (3,047).

```
exploracion.py X  README.md  limpieza.py  carga.py

exploracion.py > ...
1  import pandas as pd
2
3  # CSV anual 2023-2024 - separador ; y encoding latin-1
4  # OJO: Asegúrate de que el nombre del archivo coincida exactamente con el que descargaste
5  df = pd.read_csv('2_MINEDUC_RegistrosAdministrativos_2023-2024Inicio.csv', sep=';', encoding='latin-1')
6
7  print("--- Dimensiones del Dataset ---")
8  print(df.shape)
9
10 print("\n--- Top 15 columnas con más valores nulos ---")
11 print(df.isnull().sum().sort_values(ascending=False).head(15))
12
13 print("\n--- Distribución por Sostenimiento ---")
14 print(df['Sostenimiento'].value_counts())
15
16 print("\n--- Distribución por Nivel de Educación ---")
17 print(df['Nivel Educación'].value_counts())

PROBLEMS  OUTPUT  DEBUG CONSOLE  TERMINAL  PORTS

PS C:\Practicum1.2\practicum_datos_mineduc> & C:/Users/kb24m/AppData/Local/Programs/Python/Python314/python.exe c:/Practicum1.2
/practicum_datos_mineduc/exploracion.py
Alfabetización 11
Educación General Básica y Ofertas Intensivas 9
Educación General Básica, Bachillerato y Alfabetización 5
Alfabetización y Ofertas Intensivas 2
Educación General Básica y Alfabetización 1
Educación Inicial, Bachillerato y Ofertas Intensivas 1
Name: count, dtype: int64
PS C:\Practicum1.2\practicum_datos_mineduc>
PS C:\Practicum1.2\practicum_datos_mineduc>
```

Fase 2: Limpieza de Datos (limpieza.py)

Se construyó un script secuencial con pandas aplicando cuatro transformaciones críticas:

1. **Renombrado Estándar:** Se eliminaron tildes, espacios y caracteres especiales de las columnas de interés para asegurar la compatibilidad con motores SQL.
 2. **Imputación de Nulos:** Los valores faltantes en métricas clave (total_docentes, total_estudiantes, desagregaciones por género) se rellenaron con 0 y se convirtieron a tipo entero. El 0 representa ausencia de reporte, no necesariamente ausencia de individuos.
 3. **Deduplicación:** Se garantizó la unicidad de los registros utilizando la clave primaria compuesta por cod_amie y anio_lectivo.
 4. **Validación de Consistencia:** Se implementó una verificación matemática para asegurar que la suma de estudiantes masculinos y femeninos coincida con el total reportado.
- **Salida:** Generación del archivo transaccional mineduc_limpio.csv.

```
PS C:\Practicum1.2\practicum_datos_mineduc> & C:/Users/kb24m/AppData/Local/Programs/Python/Python314/python.exe c:/Practicum1.2/
/practicum_datos_mineduc/limpieza.py
Iniciando Fase 2: Limpieza de Datos...
1. Columnas renombradas correctamente.
2. Valores nulos convertidos a cero.
3. Duplicados eliminados. Pasamos de 16201 a 16201 filas.
4. Se encontraron 0 registros inconsistentes matemáticamente.
¡Limpieza finalizada! Archivo 'mineduc_limpio.csv' guardado.
PS C:\Practicum1.2\practicum_datos_mineduc>
```

Fase 3: Carga Relacional (carga.py)

Utilizando sqlalchemy, el dataset limpio se exportó a una base de datos relacional local.

- Se estableció la conexión automatizada a amie_mineduc.db.
- Se generó la tabla instituciones reemplazando ejecuciones previas para mantener la idempotencia del pipeline.

```
PS C:\Practicum1.2\practicum_datos_mineduc> & C:/Users/kb24m/AppData/Local/Programs/Python/Python314/python.exe c:/Practicum1.2/
/practicum_datos_mineduc/carga.py
Iniciando Fase 3: Carga en SQLite...
Filtrando datos para el año lectivo 2023-2024...
Insertando datos en la tabla 'instituciones'...
¡Carga finalizada con éxito!

--- Ejecutando consulta de verificación ---
Total de registros cargados en la tabla 'instituciones': 16201

Primeras 3 filas de la tabla:
('17H03687', 'CECOMSYS', 'Particular')
('06H00116', 'COLEGIO DE BACHILLERATO DR EUGENIO ESPEJO PCEI', 'Particular')
('01H01615', 'COLEGIO DE BACHILLERATO PARTICULAR ATLÁNTICO PCEI', 'Particular')
PS C:\Practicum1.2\practicum_datos_mineduc>
```

Fase 4: Dashboard y Visualización Analítica

Se conectó Power BI directamente a la base de datos SQLite mediante un script de extracción en Python, permitiendo modelar los datos y construir las siguientes visualizaciones:

- **KPI Global:** Un recuento total que muestra ~4 millones de estudiantes matriculados a nivel nacional.
- **P1 - Matrícula por Provincia:** Gráfico de barras horizontales que evidencia la concentración de estudiantes, liderada por las provincias de Guayas y Pichincha.

- **P2 - Proporción Institucional en Loja:** Gráfico de barras apiladas al 100% filtrado a nivel de objeto visual exclusivamente para la provincia de Loja, contrastando el sostenimiento (Fiscal, Fiscomisional, Particular, Municipal) segmentado por zona Urbana y Rural.
- **P3 - Evolución Temporal:** Estructura de línea temporal por anio_lectivo vs Recuento de cod_amie