

PIPELINE DE DATOS · ARQUITECTURA MEDALLION

Del dato crudo al tablero de control

Avance de Practicum 1.2 — Semanas 3, 4 y 5

Limpieza de fuentes · Modelo relacional y vistas Gold · Dashboard en Power BI

El pipeline en tres capas

Cada fuente del macroentorno ecuatoriano pasa por el mismo camino antes de llegar a un gráfico.



Bronze

Archivos fuente tal como los entregan BCE, INEC, Supercías y MINEDUC: Excel, CSV, algunos de más de 300 MB.



Silver

Scripts en Pandas limpian, normalizan y reshapean cada fuente (melt, dtype, streaming con openpyxl para los archivos pesados).



Gold

Vistas SQL sobre el modelo relacional final, listas para conectarse directo a Power BI.

Semana 3 — Limpiando cuatro fuentes muy distintas



INEC · ENEMDU

Los indicadores laborales venían con las áreas (nacional/urbana/rural) como columnas. Usé `pd.melt()` para pasarlos a formato largo antes de cargarlos.



INEC · Censo 2022

La hoja de ocupación traía 22 ramas de actividad, una por columna. Mismo truco de `melt()` para dejar una rama por fila.



Supercías


El ranking de empresas (326 MB) no traía RUC ni provincia, solo un número de expediente. Tocó cruzarlo con el directorio de compañías para completar los datos.



MINEDUC

Pensé que era el AMIE de un solo año. Resultó ser un histórico 2009-2024 con 322 mil filas y 109 columnas — cambié de `pandas` a `openpyxl` en modo streaming para no reventar la memoria.

Modelo Entidad Relacion



Semana 4 — De tablas planas a un modelo relacional


Las tablas sueltas de la Semana 2 y 3 se archivaron como staging y se reconstruyeron con llaves foráneas reales.

2 dimensiones + 2 catálogos + 8 hechos

- dim_geografia — provincia/cantón normalizados (mayúsculas, sin tildes)
- dim_tiempo — series anuales de PIB y empleo
- dim_empresas / dim_ciiu — directorio y catálogo de Supercías
- 8 tablas de hechos con FK: PIB, VAB, empleo, censo, ranking empresarial, oferta académica...

PIB real de Ecuador, 1965–2024

Datos reales de gold_pib_tendencia (fact_macro_anual)



Las cinco vistas Gold

Cada una responde una pregunta concreta y alimenta directamente un visual en Power BI.

gold_pib_tendencia

Evolución del PIB con clasificación de ciclo económico (Crecimiento fuerte / moderado / Estancamiento / Contracción).

gold_empleo_tendencia

Tasa de desempleo nacional, urbana y rural por trimestre, desde 2007.

gold_petroleo_30dias

Promedio móvil de 30 días del precio del petróleo WTI, con window function.

gold_empresas_provincia

Empresas activas, ingresos y activos totales agrupados por provincia.

gold_bachilleres_vs_empresas

Cruce entre bachilleres de 3er año y empresas activas — la pregunta P3 del dashboard.

Antes de conectar Power BI, verifiqué la integridad

PRAGMA foreign_key_check sobre la base migrada — cero violaciones.

0

violaciones de FK
en toda la base

1.52M

filas en el ranking
empresarial migradas

322,602

filas del histórico
MINEDUC (2009–2024)

60




años de series anuales
de PIB y población



Un pendiente que documenté: cerca del 21% de las filas de Supercías y el 9.5% del Censo quedaron sin id_geografia (nombres de provincia/cantón que no calzaron al normalizar). No rompe nada — la vista gold_empresas_provincia simplemente las excluye — pero lo anoté como limitación conocida.

Semana 5 — Dashboard, página P1

“¿Cómo ha evolucionado la economía ecuatoriana en los últimos 20 años?”



Qué responde cada visual

- Línea de PIB real anual, 1965–2024
- Barras de variación (%) coloreadas por ciclo económico
- KPI: PIB per cápita más reciente y variación interanual
- Contexto: Índice de Expectativas Empresariales del último año


Semana 5 — Dashboard, página P2 y lo que sigue

“¿En qué sectores y provincias se concentran la actividad económica y el empleo?”

Valor Agregado Bruto por Provincia



Top 10 Ramas de Actividad por Personas Ocupadas



3,04

Desempleo más reciente



Lo que sigue

- Cerrar el acuerdo de integración con el equipo de RPA (formato de archivo y carpeta de entrada)
- Construir pipeline.py para detectar y procesar archivos nuevos automáticamente
- Semana 6: página P3 (bachilleres vs. empresas) y filtros por año/provincia/sector