

IMPLEMENTACIÓN DE UN PIPELINE DE DATOS EN ARQUITECTURA MEDALLION

Integración de fuentes oficiales del macroentorno ecuatoriano y automatización de extracción vía RPA

Daniel Matute

Ingeniería en Computación, Universidad Técnica Particular de Loja (UTPL)

Practicum 1.2 — Ingeniería, Analítica y Visualización de Datos

Resumen

Este informe documenta el diseño, la implementación y la validación de un pipeline de datos siguiendo la arquitectura Medallion (Bronze-Silver-Gold) para consolidar indicadores del macroentorno ecuatoriano provenientes de cuatro fuentes oficiales: el Banco Central del Ecuador (BCE), el Instituto Nacional de Estadística y Censos (INEC), la Superintendencia de Compañías, Valores y Seguros (Supercías) y el Ministerio de Educación (MINEDUC). El sistema transforma archivos fuente heterogéneos en un modelo relacional dimensional con integridad referencial verificada, expuesto finalmente en un dashboard interactivo de Power BI organizado en tres páginas analíticas.

Durante el desarrollo se incorporó una fuente adicional de datos, extraída automáticamente mediante un proceso de automatización robótica (RPA) sobre un sistema Oracle, lo que requirió resolver problemas de configuración de base de datos, corregir errores de transformación de datos previamente no detectados, y diseñar estrategias diferenciadas de integración (reemplazo, combinación, creación de nuevas tablas o bloqueo documentado) según la naturaleza y calidad de cada conjunto de datos. El resultado final integra aproximadamente 1.95 millones de registros adicionales, mantiene cero violaciones de integridad referencial verificadas mediante PRAGMA foreign_key_check, y documenta explícitamente las limitaciones de calidad de datos encontradas.

Palabras clave: arquitectura Medallion, pipeline de datos, ETL, integridad referencial, Power BI, RPA, macroentorno económico, Ecuador.

I. Introducción

El Ecuador dispone de múltiples fuentes de datos públicos y oficiales sobre su macroentorno económico, empresarial, laboral y educativo, pero estas fuentes se encuentran dispersas, en formatos heterogéneos y sin un modelo de datos común que permita su análisis conjunto. El Banco Central del Ecuador publica series macroeconómicas (PIB, Valor Agregado Bruto, precio del petróleo, riesgo país); el INEC publica encuestas de empleo (ENEMDU) y datos censales; la Superintendencia de Compañías mantiene el directorio y ranking financiero de las empresas activas en el país; y el Ministerio de Educación mantiene el registro histórico de matrícula y oferta académica.

El objetivo de este proyecto fue construir un pipeline de datos reproducible, no dependiente de procesos manuales, capaz de consolidar estas cuatro fuentes en un modelo relacional único con llaves foráneas verificadas, y de exponer los resultados mediante un tablero de Power BI orientado a tres preguntas analíticas concretas: la evolución de la economía nacional, la concentración territorial de la actividad económica y el empleo, y la relación entre la oferta educativa (bachilleres) y el tejido empresarial por provincia.

El proyecto se desarrolló en fases semanales, comenzando por el diseño de la arquitectura de capas (Semana 1), continuando con la limpieza individual de cada fuente (Semanas 2 y 3), la construcción del modelo relacional dimensional (Semana 4), la implementación del dashboard inicial (Semana 5) y, finalmente, la incorporación de una fuente adicional de datos extraída mediante automatización robótica de procesos (RPA), que constituye la principal contribución técnica adicional documentada en este informe.

II. Metodología

Se adoptó la arquitectura Medallion, que organiza el flujo de datos en tres capas sucesivas de refinamiento:

- **Bronze:** datos crudos, tal como se reciben de cada fuente (archivos Excel, CSV, y posteriormente volcados de Oracle Data Pump).

- Silver: datos limpios, normalizados y estructurados en un modelo relacional con llaves primarias y foráneas, almacenado en SQLite.
- Gold: vistas analíticas derivadas del modelo Silver, optimizadas para consumo directo desde Power BI.

Las herramientas empleadas fueron Python (con las bibliotecas pandas y openpyxl) para la transformación de datos, SQLite como motor de almacenamiento relacional, Oracle Database Express Edition 21c para el procesamiento intermedio de los datos extraídos vía RPA, Prefect como orquestador del flujo ETL correspondiente a dicha fuente, y Microsoft Power BI, conectado mediante un controlador ODBC, como capa de visualización.

A. Limpieza de fuentes originales (Semanas 2 y 3)

Cada una de las cuatro fuentes presentó un reto técnico distinto. Los datos de INEC (ENEMDU y Censo 2022) requirieron una transformación de formato ancho a formato largo mediante la función `pd.melt()` de pandas, ya que las áreas y ramas de actividad se encontraban distribuidas como columnas en lugar de como valores de fila. El directorio de Supercías incluía un archivo de 326 MB que solo contenía el número de expediente de cada empresa, por lo que fue necesario cruzarlo con un directorio complementario para recuperar el RUC y la provincia de cada compañía. El registro histórico de MINEDUC resultó ser un archivo de 313 MB correspondiente al periodo 2009-2024 (322 602 filas), sensiblemente distinto del archivo de una sola cohorte que se había asumido inicialmente, y su tamaño exigió una lectura en flujo (streaming) mediante la biblioteca openpyxl en lugar de una carga completa en memoria.

B. Modelo relacional dimensional (Semana 4)

El modelo resultante adopta un esquema dimensional compuesto por cuatro tablas de dimensión (`dim_geografia`, `dim_tiempo`, `dim_empresas` y `dim_ciiu`) y ocho tablas de hechos que cubren el producto interno bruto, el valor agregado bruto, el empleo, la ocupación censal, el ranking empresarial, la oferta académica, los indicadores diarios de mercado y el índice de expectativas empresariales. El esquema fue adaptado desde un diseño original en PostgreSQL hacia SQLite, sustituyendo el tipo `SERIAL` por `INTEGER PRIMARY KEY AUTOINCREMENT`. La integridad referencial del modelo se verificó de forma sistemática mediante la instrucción `PRAGMA foreign_key_check`, no reportando violaciones al cierre de esta fase, aunque se documentó que aproximadamente el 21% de las filas de `fact_ranking_empresarial` y el 9.5% de `fact_ocupacion_censo` quedaban sin asignación de geografía debido a discrepancias en la normalización de nombres de provincia y cantón entre fuentes.

C. Dashboard inicial (Semana 5)

Se implementó una primera versión del tablero con dos páginas, conectadas al modelo relacional mediante un controlador ODBC para SQLite. La primera página aborda la evolución histórica de la economía (PIB real, variación interanual e Índice de Expectativas Empresariales); la segunda aborda la concentración geográfica de la actividad económica y el empleo.

D. Incorporación de una fuente adicional vía RPA (Semanas 5-6)

Un proceso de automatización robótica desarrollado por un integrante del equipo extrajo indicadores oficiales adicionales directamente desde los sistemas fuente, entregando el resultado como dos archivos de exportación de Oracle Data Pump (323 KB y 2.4 GB respectivamente), cada uno conteniendo una única tabla, `TAB_CONSOLIDADO`, en la que cada fila corresponde a un indicador distinto almacenado como texto JSON. Los datos JSON se encontraban doblemente serializados —una cadena de texto que contiene, a su vez, otra cadena JSON escapada— lo que exigió aplicar la función de deserialización `json.loads()` en dos pasadas sucesivas antes de poder aplanar la estructura mediante `pandas.json_normalize()`.

La carga de estos archivos en una instancia local de Oracle Database XE 21c presentó dos incompatibilidades de esquema: el uso de un tablespace inexistente en la instalación local, y la declaración de la columna identificadora como GENERATED ALWAYS AS IDENTITY, incompatible con los valores explícitos de clave primaria incluidos en las instrucciones de inserción del archivo fuente. Ambas incompatibilidades se resolvieron modificando la definición de la tabla antes de la carga.

III. Resultados

A. Volumen de datos integrados

La incorporación de la fuente RPA añadió catorce indicadores distintos al sistema, sumando aproximadamente 1.95 millones de registros nuevos, distribuidos como se resume en la Tabla 1.

Archivo	Tamaño	Filas cargadas
tab consolidado export.sql	323 KB	277 529
tab consolidado supercias.sql	2.4 GB	1 672 590

B. Estrategias de integración por tabla

No todos los conjuntos de datos extraídos vía RPA se integraron de la misma manera al modelo dimensional existente. La estrategia se seleccionó según si la nueva fuente representaba una mejora directa sin pérdida de información, un período temporal adicional, una estructura de datos incompatible con la tabla existente, o si el propio dato de origen presentaba un defecto que impedía su uso. La Tabla 2 resume las decisiones tomadas.

Tabla	Estrategia	Resultado
dim empresas	Reemplazo	219 753 filas
fact ranking empresarial	Reemplazo	1 345 488 filas
fact oferta academica	Combinación (append)	+16 275 filas (periodo 2025-2026)
fact macro anual	Actualización (PIB nominal)	60/60 años sin valores nulos
fact empleo poblacion	Tabla nueva	1 872 filas
fact vab	Bloqueado	Campo anio nulo desde el origen

El reemplazo de dim_empresas y fact_ranking_empresarial se justificó porque los datos vía RPA representaban una versión más completa y actualizada (fecha de reporte 2026-07) que los datos estáticos originales, sin pérdida de información relevante. En contraste, fact_oferta_academica se combinó en lugar de reemplazarse, dado que la fuente RPA solo cubría el periodo lectivo 2025-2026, mientras que el registro histórico original cubría 2009-2024; se verificó la ausencia de solapamiento de periodos antes de realizar la inserción. La tabla fact_vab permanece bloqueada porque el indicador VAB_CANTONAL_CIIU entregado por RPA presenta el campo anio nulo en el dato de origen, un defecto pendiente de reporte al equipo responsable de la extracción.

C. Corrección de errores de software

Durante la validación de los resultados se identificaron y corrigieron seis errores de transformación de datos, resumidos en la Tabla 3.

Problema identificado	Causa raíz
Rechazo de carga en Oracle (ORA-32795 / ORA-00955)	Tablespace inexistente y columna IDENTITY mal configurada

Subconteo de bachilleres (solo mujeres)	Selección de una sola columna cuando existían columnas separadas por sexo
Pérdida del detalle urbano/rural en empleo	Mismo patrón: se descartaban las columnas de área urbana y rural
PIB nominal ausente en 35 de 60 años	El proceso ETL nunca consultaba el indicador PIB NOMINAL PER CAPITA
RUC y código CIU vacíos violando llaves única/foránea	Registros administrativos sin identificador asignado (empresas disueltas)
Caracteres ilegibles en consola (mojibake)	Codificación de página de la terminal, sin afectar los datos almacenados

Es de particular relevancia el patrón repetido en los errores segundo y tercero: en ambos casos, el código de transformación seleccionaba una única columna coincidente con un patrón de texto (por ejemplo, la primera columna que contuviera la palabra “nacional”) sin considerar que el esquema de origen contenía variantes adicionales (columnas para hombres, mujeres, área urbana y área rural) que quedaban descartadas silenciosamente. Este hallazgo sugiere la conveniencia de preferir, en futuros desarrollos, una validación explícita del conjunto completo de columnas esperadas antes de aplicar heurísticas de selección por coincidencia de texto.

D. Verificación de integridad referencial

Como cierre de la fase de integración de código, se formalizó una llave foránea que existía únicamente de manera implícita en los datos: las columnas `ciiu_n1` y `ciiu_n6` de `dim_empresas`, `ciiu_n6` de `fact_ranking_empresarial`, y `ciiu` de `fact_vab`, se declararon formalmente como referencias a `dim_ciiu(ciiu)`. Dado que SQLite no admite la instrucción `ALTER TABLE ADD FOREIGN KEY`, fue necesario reconstruir cada tabla afectada conservando sus datos. Durante este proceso se detectaron 524 violaciones de integridad, atribuibles a 262 registros con código CIU vacío (cadena de texto vacía en lugar de valor nulo), las cuales se corrigieron convirtiendo dichos valores a NULL antes de confirmar la restricción. Tras la corrección, la verificación mediante `PRAGMA foreign_key_check` no reportó violaciones.

E. Dashboard final

El tablero de Power BI resultante consta de tres páginas interconectadas mediante botones de navegación: la evolución histórica de la economía (P1), la concentración de la actividad económica y el empleo por provincia (P2), y la relación entre bachilleres egresados y empresas activas por provincia (P3). Cada página incluye segmentaciones de datos interactivas (por año, provincia y sector), indicadores clave de desempeño calculados mediante medidas DAX, y una paleta de colores institucional aplicada de forma consistente, incluyendo formato condicional que colorea en verde los valores positivos y en rojo los valores negativos en los gráficos de variación económica.

IV. Discusión

Los resultados evidencian que la integración de una fuente de datos adicional a un modelo ya existente no puede tratarse como un problema homogéneo de sustitución de datos: cada tabla exigió un análisis particular de compatibilidad temporal, granularidad y completitud antes de decidir la estrategia de integración adecuada. En al menos dos casos (`fact_macro_anual` y `fact_empleo_poblacion`) se identificó que el proceso automatizado de extracción no cubría la totalidad de los campos requeridos por el modelo original —el PIB nominal y el detalle urbano/rural del empleo, respectivamente—, lo cual habría pasado inadvertido de no haberse contrastado explícitamente contra el esquema de destino.

Asimismo, se identificó que la tabla `fact_ocupacion_censo`, correspondiente a los datos del Censo 2022, no ha sido todavía cubierta por el proceso de extracción vía RPA, a pesar de que los indicadores `CENSO_RAMA_ACTIVIDAD` y `CENSO_GRUPO_OCUPACION` sí se encuentran disponibles en el origen Oracle. En consecuencia, los archivos fuente originales de esta tabla deben conservarse hasta que dicha integración se complete, dado que constituyen actualmente su única fuente de datos.

Finalmente, se documenta como limitación conocida el bloqueo de la tabla `fact_vab` por un defecto de origen (campo anio nulo) ajeno al alcance de este trabajo, y la cobertura parcial (19.56% de registros sin correspondencia) entre el ranking financiero histórico y el directorio de empresas vigente, atribuible a la presencia de empresas ya disueltas en el histórico de ranking.

V. Conclusiones

Se implementó exitosamente un pipeline de datos en arquitectura Medallion que consolida cuatro fuentes oficiales del macroentorno ecuatoriano en un modelo relacional dimensional con integridad referencial verificada, y se amplió dicho modelo mediante la incorporación de una fuente adicional extraída por automatización robótica de procesos, aplicando en cada caso una estrategia de integración de datos justificada por el análisis de compatibilidad correspondiente.

El proceso de depuración permitió identificar y corregir errores de transformación de datos no detectados en versiones anteriores del proceso ETL, en particular un patrón recurrente de pérdida de información por selección incompleta de columnas de origen. El resultado final se expone en un dashboard de tres páginas con navegación, filtros interactivos y formato visual condicional, quedando documentadas explícitamente las limitaciones de datos identificadas para su seguimiento posterior.

Referencias

- [1] Banco Central del Ecuador, “Cuentas Nacionales y Estadísticas Macroeconómicas,” BCE, Quito, Ecuador.
- [2] Instituto Nacional de Estadística y Censos, “Encuesta Nacional de Empleo, Desempleo y Subempleo (ENEMDU) y Censo de Población y Vivienda 2022,” INEC, Quito, Ecuador.
- [3] Superintendencia de Compañías, Valores y Seguros, “Directorio de Compañías y Ranking Empresarial,” SCVS, Quito, Ecuador.
- [4] Ministerio de Educación del Ecuador, “Registro Administrativo de Instituciones Educativas (AMIE),” MINEDUC, Quito, Ecuador.